

1 Introduction
2 Exploration des données
3 Conclusion

B2-Spirit : Exploration interactive du trafic aérien mondial

Projet IF36 – Université de Technologie de Troyes
2026-04-19

1 Introduction

1.1 Données

Notre projet repose sur l'assemblage de plusieurs sources de données de référence dans le domaine de l'aviation ouverte, que nous croiserons pour construire une vision riche et multidimensionnelle du trafic aérien mondial.

1.1.1 Source principale : OpenSky Network – COVID-19 Flight Dataset

Le cœur de notre analyse s'appuie sur le **OpenSky Network COVID-19 Flight Dataset**, publié sur Zenodo (<https://zenodo.org/records/7923702>) sous licence CC-BY. Ce dataset recense l'ensemble des vols captés par le réseau collaboratif OpenSky entre **janvier 2019 et décembre 2022**.

Les données sont issues du protocole **ADS-B** : les avions diffusent automatiquement leur position, vitesse et identification, captées par un réseau de plus de 5 500 récepteurs au sol. En période de pointe pré-pandémie, près de 100 000 vols étaient suivis par jour.

Format : Fichiers CSV mensuels (48 fichiers au total).

Volume : Plus de **41 millions de vols**, couvrant environ **160 000 aéronefs** et **13 900 aéroports** dans **127 pays**.

Les variables principales du dataset sont les suivantes :

Variable	Type	Description
callsign	Catégorielle	Identifiant du vol (ex : AFR = Air France)

Variable	Type	Description
icao24	Catégorielle	Identifiant unique du transpondeur
typecode	Catégorielle	Code OACI du modèle d'aéronef (ex : A320, B738)
origin	Catégorielle	Code OACI de l'aéroport d'origine
destination	Catégorielle	Code OACI de l'aéroport de destination
firstseen	Temporelle	Timestamp UTC du premier signal ADS-B
lastseen	Temporelle	Timestamp UTC du dernier signal ADS-B
day	Temporelle	Jour UTC du dernier signal
latitude_1/2	Continue	Latitude de la première/dernière position
longitude_1/2	Continue	Longitude de la première/dernière position
altitude_1/2	Continue	Altitude barométrique au départ/à l'arrivée

1.1.2 Sources complémentaires

- **OpenSky Aircraft Database** : métadonnées aéronefs (modèle, opérateur, propriétaire), jointure sur icao24
- **OurAirports** : ~78 000 aéroports avec coordonnées GPS, continent, pays, code OACI
- **OpenFlights** : ~6 200 compagnies aériennes et ~67 600 routes commerciales

1.1.3 Pourquoi ces données ?

Le trafic aérien est un miroir de l'activité humaine à l'échelle planétaire. La période 2019–2022 capture un événement historique sans précédent : l'effondrement puis la reconstruction progressive du transport aérien mondial due à la pandémie de COVID-19.

1.2 Plan d'analyse

Nos questions s'articulent autour de quatre axes :

- **Axe 1** — Dynamiques temporelles du trafic (Q1, Q2)
- **Axe 2** — Géographie du ciel et cartographie des flux (Q3, Q4, Q5)
- **Axe 3** — Analyse de la flotte mondiale (Q6, Q7)

- **Axe 4** — Stratégies et résilience des compagnies (Q8, Q9)

Pour ce premier livrable, chaque membre du groupe répond à une question de ce plan d'analyse.

2 Exploration des données

```
flights <- read_csv("C:/Users/AMIR/Downloads/clean_COVID_19_Flightfile.csv")
```

2.1 Le trafic aérien a-t-il un rythme cardiaque ? (Q2)

Nous cherchons ici à déterminer si le trafic aérien mondial suit des cycles réguliers comparables à un “rythme cardiaque”, c’est-à-dire des variations prévisibles selon l’heure de la journée, le jour de la semaine ou encore le mois de l’année. Nous pouvons supposer que l’activité aérienne est plus intense à certaines heures de la journée, notamment le matin en Europe puis plus tard dans la journée en Amérique du Nord. Nous pouvons également imaginer que certains jours, comme le dimanche, sont plus calmes que les jours ouvrés.

Pour répondre à cette question, nous avons construit trois visualisations : un graphique linéaire du nombre de vols par heure (UTC), un diagramme en barres du nombre de vols par jour de la semaine, et un diagramme en barres du nombre de vols par mois.

Les données utilisées proviennent de notre dataset couvrant l’ensemble de l’année 2019. Cette période a été retenue car le trafic aérien n’était alors pratiquement pas affecté par la pandémie de COVID-19, ce qui permet d’observer un fonctionnement plus représentatif du rythme habituel de l’aviation mondiale.

Cependant, le volume total de données étant particulièrement important, nous avons choisi de travailler sur un échantillon aléatoire de 1% des observations, suffisant pour mettre en évidence les grandes tendances tout en réduisant le temps de calcul et la charge mémoire.

2.1.1 Variation du trafic aérien selon l’heure de la journée (UTC)


Afin d’étudier l’existence d’un rythme journalier du trafic aérien mondial, nous avons calculé le nombre moyen de vols observés pour chaque heure de la journée (UTC), en moyennant les volumes sur l’ensemble des jours de l’année 2019.

```

flights_heure <- flights %>%
  mutate(heure = hour(as.POSIXct(firstseen, format = "%Y-%m-%dT%H:%M:%SZ", tz = "UTC"))) %>%
  filter(!is.na(heure)) %>%
  count(day, heure) %>%
  group_by(heure) %>%
  summarise(moy_vols = mean(n))

ggplot(flights_heure, aes(x = heure, y = moy_vols)) +
  geom_line(color = "#2166ac", linewidth = 1.2) +
  geom_point(color = "#2166ac", size = 2) +
  scale_x_continuous(breaks = 0:23) +
  labs(
    title = "Nombre moyen de vols par heure de la journée (UTC) en 2019",
    x = "Heure (UTC)",
    y = "Nombre moyen de vols",
    caption = "Source : OpenSky Network COVID-19 Flight Dataset"
  ) +
  theme_minimal(base_size = 13) +
  theme(plot.title = element_text(face = "bold"))

```



Source : OpenSky Network COVID-19 Flight Dataset


Le graphique montre une évolution cyclique très nette du trafic au cours de la journée. Le volume de vols reste relativement élevé à 0h UTC, puis diminue progressivement durant la nuit pour atteindre un minimum entre 3h et 5h UTC. Cette phase creuse correspond principalement à la nuit en Europe et en

Afrique. À partir de 6h UTC, le trafic recommence à augmenter progressivement avec le début de journée en Europe. Le maximum est atteint vers 15h UTC, période qui correspond à un chevauchement entre l'Europe encore active et le début des opérations matinales en Amérique du Nord.

2.1.2 Variation du trafic aérien selon le jour de la semaine

```
flights_jour <- flights %>%
  mutate(jour = wday(as.Date(day), label = TRUE, abbr = FALSE, week_start = 1)) %>%
  filter(!is.na(jour)) %>%
  count(day, jour) %>%
  group_by(jour) %>%
  summarise(moy_vols = mean(n))

ggplot(flights_jour, aes(x = jour, y = moy_vols, fill = jour)) +
  geom_col(show.legend = FALSE) +
  scale_fill_brewer(palette = "Blues") +
  labs(
    title = "Nombre moyen de vols par jour de la semaine (2019)",
    x = "Jour de la semaine",
    y = "Nombre moyen de vols",
    caption = "Source : OpenSky Network COVID-19 Flight Dataset"
  ) +
  theme_minimal(base_size = 13) +
  theme(plot.title = element_text(face = "bold"))
```




Source : OpenSky Network COVID-19 Flight Dataset

Le graphique montre une variation relativement modérée du trafic au cours de la semaine. Les jours ouvrés présentent les niveaux les plus élevés, avec une progression jusqu'au vendredi. Le week-end affiche une légère baisse, notamment le samedi, ce qui correspond à une réduction des vols liés aux déplacements professionnels.

2.1.3 Variation du trafic aérien selon le mois de l'année

```
flights_mois <- flights %>%
  mutate(mois = month(as.Date(day), label = TRUE, abbr = TRUE)) %>%
  filter(!is.na(mois)) %>%
  count(mois)

ggplot(flights_mois, aes(x = mois, y = n, fill = n)) +
  geom_col(show.legend = FALSE) +
  scale_fill_gradient(low = "#9ecae1", high = "#08519c") +
  scale_y_continuous(labels = scales::comma) +
  labs(
    title = "Nombre de vols par mois de l'année (2019)",
    x = "Mois",
    y = "Nombre de vols",
    caption = "Source : OpenSky Network COVID-19 Flight Dataset"
  ) +
  theme_minimal(base_size = 13) +
  theme(plot.title = element_text(face = "bold"))
```



Source : OpenSky Network COVID-19 Flight Dataset

Le graphique met en évidence une variation saisonnière nette du trafic aérien, avec un creux en début d'année et un pic durant l'été en juillet-août. Cette période correspond à la haute saison touristique dans l'hémisphère nord.

2.1.4 Conclusion

L'analyse confirme que le trafic aérien mondial possède bien un "rythme cardiaque". Des cycles nets apparaissent selon l'heure de la journée, le jour de la semaine et le mois de l'année, structurés par les fuseaux horaires, les rythmes économiques et les saisons touristiques.

2.2 Quels avions dominant le ciel ? (Q6)

Nous cherchons ici à identifier les types d'aéronefs les plus utilisés dans le trafic aérien mondial en 2019, et à comprendre comment la flotte se répartit entre les différents constructeurs. On peut supposer que quelques modèles très répandus, comme l'Airbus A320 ou le Boeing 737, concentrent une grande partie du trafic mondial, tandis que d'autres types d'appareils occupent des niches plus spécialisées.

Pour répondre à cette question, nous avons construit trois visualisations : un diagramme en barres des 15 types d'aéronefs les plus fréquents, un diagramme en barres de la répartition par famille de constructeur, et un graphique linéaire de l'évolution mensuelle par famille.

Il est important de noter que 24,6% des vols ne disposent pas de typecode renseigné. Ces observations ont été retirées de l'analyse. Les résultats reflètent donc uniquement les vols pour lesquels le type d'aéronef est connu.

```
flights_clean <- flights %>%  
  filter(!is.na(typecode), typecode != "NA", typecode != "")
```


2.2.1 Top 15 des types d'aéronefs les plus fréquents

```
top15 <- flights_clean %>%
  count(typecode, sort = TRUE) %>%
  slice_head(n = 15) %>%
  mutate(typecode = fct_reorder(typecode, n))

ggplot(top15, aes(x = typecode, y = n, fill = n)) +
  geom_col(show.legend = FALSE) +
  coord_flip() +
  scale_fill_gradient(low = "#9ecae1", high = "#08519c") +
  scale_y_continuous(labels = scales::comma) +
  labs(
    title = "Top 15 des types d'aéronefs les plus fréquents (2019)",
    subtitle = "Basé sur 1% du dataset OpenSky – 312 177 vols",
    x = "Type d'aéronef (code OACI)",
    y = "Nombre de vols",
    caption = "Source : OpenSky Network COVID-19 Flight Dataset"
  ) +
  theme_minimal(base_size = 13) +
  theme(
    plot.title = element_text(face = "bold"),
    panel.grid.major.y = element_blank()
  )
```


Top 15 des types d'aéronefs les plus fréquents (2019)

Basé sur 1% du dataset OpenSky — 312 177 vols



Source : OpenSky Network COVID-19 Flight Dataset

Le graphique révèle une concentration très marquée du trafic autour de deux modèles dominants. Le Boeing 737-800 (B738) arrive en tête avec environ 43 000 vols, suivi de près par l'Airbus A320 avec environ 38 500 vols. Ces deux modèles reflètent leur popularité auprès des compagnies aériennes pour les vols court et moyen-courriers. Les modèles A321 et A319 appartiennent également à la famille A320 d'Airbus, confirmant la domination de cette gamme. Plus loin dans le classement, on trouve des appareils régionaux comme l'Embraer E75L ou le Bombardier CRJ9, ainsi que le Boeing 777 (B77W) représentant le segment long-courrier.

2.2.2 Répartition par famille de constructeur


```
flights_famille <- flights_clean %>%
  mutate(famille = case_when(
    str_starts(typecode, "A3") | str_starts(typecode, "A2") |
      str_starts(typecode, "A1") ~ "Airbus",
    str_starts(typecode, "B7") ~ "Boeing",
    str_starts(typecode, "E") ~ "Embraer",
    str_starts(typecode, "CRJ") ~ "Bombardier CRJ",
    str_starts(typecode, "AT") ~ "ATR",
    str_starts(typecode, "DH") ~ "De Havilland",
    TRUE ~ "Autres"
  ))

famille_count <- flights_famille %>%
  count(famille, sort = TRUE) %>%
  mutate(
    pct = n / sum(n) * 100,
    famille = fct_reorder(famille, n)
  )

ggplot(famille_count, aes(x = famille, y = n, fill = famille)) +
  geom_col(show.legend = FALSE) +
  geom_text(aes(label = paste0(round(pct, 1), "%")), hjust = -0.1, size = 4) +
  coord_flip() +
  scale_y_continuous(
    labels = scales::comma,
    expand = expansion(mult = c(0, 0.15))
  ) +
  scale_fill_brewer(palette = "Set2") +
  labs(
    title = "Répartition des vols par famille de constructeur (2019)",
    subtitle = "Airbus et Boeing dominant largement le marché",
    x = "Famille d'aéronef",
    y = "Nombre de vols",
    caption = "Source : OpenSky Network COVID-19 Flight Dataset"
  ) +
  theme_minimal(base_size = 13) +
  theme(
    plot.title = element_text(face = "bold"),
    panel.grid.major.y = element_blank()
  )
```

Répartition des vols par famille de constructeur (2019)

Airbus et Boeing dominent largement le marché



Source : OpenSky Network COVID-19 Flight Dataset

Le graphique confirme le duopole Boeing-Airbus sur le marché aérien mondial. Boeing représente 35,3% des vols et Airbus 34,7%, soit ensemble près de 70% du trafic total. Cet équilibre quasi parfait illustre la compétition intense qui structure le marché depuis plusieurs décennies. Les constructeurs régionaux Embraer (8,1%) et Bombardier CRJ (4,9%) se spécialisent sur les vols régionaux, tandis qu'ATR (1,5%) et De Havilland (1,5%) couvrent les liaisons locales.


2.2.3 Évolution mensuelle par famille d'aéronef

```
flights_mensuel <- flights_famille %>%
  mutate(mois = month(as.Date(day), label = TRUE, abbr = TRUE)) %>%
  filter(famille %in% c("Airbus", "Boeing", "Embraer",
                       "Bombardier CRJ", "ATR")) %>%
  count(mois, famille)

ggplot(flights_mensuel, aes(x = mois, y = n,
                           color = famille, group = famille)) +
  geom_line(linewidth = 1.2) +
  geom_point(size = 2.5) +
  scale_color_brewer(palette = "Set1") +
  scale_y_continuous(labels = scales::comma) +
  labs(
    title = "Évolution mensuelle des vols par famille d'aéronef (2019)",
    subtitle = "Saisonnalité estivale visible pour toutes les familles",
    x = "Mois",
    y = "Nombre de vols",
    color = "Constructeur",
    caption = "Source : OpenSky Network COVID-19 Flight Dataset"
  ) +
  theme_minimal(base_size = 13) +
  theme(
    plot.title = element_text(face = "bold"),
    legend.position = "bottom"
  )
)
```

Évolution mensuelle des vols par famille d'aéronef (2019)

Saisonnalité estivale visible pour toutes les familles



Source : OpenSky Network COVID-19 Flight Dataset

Boeing et Airbus suivent des courbes très similaires tout au long de l'année, avec un creux en février et un pic estival en juillet-août, confirmant qu'ils opèrent sur les mêmes marchés et subissent les mêmes effets de saisonnalité touristique. Embraer présente une tendance à la hausse progressive sur l'année, tandis que Bombardier CRJ et ATR restent stables.

2.2.4 Conclusion

La flotte aérienne mondiale en 2019 est dominée par Boeing et Airbus qui se partagent près de 70% du trafic avec un équilibre remarquable. Le Boeing 737-800 et l'Airbus A320 concentrent à eux seuls une part majeure des vols, reflétant leur positionnement idéal sur le segment court et moyen-courrier qui représente la grande majorité des liaisons aériennes mondiales.

2.3 Question 3 — À compléter par [Prénom membre 3]

TODO : Ajouter ici ta question, ton code R et ton analyse.

2.4 Question 4 — À compléter par [Prénom membre 4]

TODO : Ajouter ici ta question, ton code R et ton analyse.

3 Conclusion

Cette section sera complétée lors du rapport final.